

Replicação e Otimização do Modelo RoBERTa-BiLSTM para Análise de Sentimentos

1. Metodologia: A Arquitetura Híbrida Base

A replicação manteve estritamente o núcleo arquitetural proposto por Rahman *et al.* (2025). O pipeline utiliza o modelo **RoBERTa-base** atrelado ao seu respectivo tokenizador dinâmico para atuar como o extrator contextual primário. Os tensores gerados (com 768 dimensões ocultas) passam por uma camada de *Dropout* (0.1) e são alimentados em uma rede **BiLSTM** com 256 unidades ocultas. A natureza bidirecional da LSTM captura dependências sequenciais de longo alcance no texto, mitigando o esquecimento de contexto. A rede finaliza com camadas densas (Fully Connected) e uma função de ativação Softmax para a classificação de sentimentos (binária ou multiclasse).

2. Melhorias Metodológicas e Otimização do Pipeline

Embora a matemática da rede tenha sido preservada, a estratégia de treino foi substancialmente reestruturada para garantir maior generalização e eficiência computacional. As três principais alterações em relação ao estudo original foram:

1. **Rigor na Exposição de Dados (Split 90/5/5 Autêntico):** O artigo original indicou intenção de usar 90% dos dados para treino, mas as métricas de validação indicaram sub-amostragem (especialmente no *Sentiment140*). O nosso pipeline garantiu o carregamento completo via Hugging Face, alimentando a rede com a totalidade dos 90% reais (resultando em mais de 1,44 milhões de instâncias de treino no maior dataset).
2. **Aceleração com Automatic Mixed Precision (AMP):** O treino num hardware de consumo (GPU RTX 4060 Ti de 8GB) num dataset massivo seria impossível devido ao limite de VRAM e processamento em precisão total (FP32). Implementou-se o suporte a AMP (16-bits), o que dividiu o uso de memória pela metade e permitiu treinar 1.44M de tweets em um tempo viável de ~14 horas.
3. **Regularização por Early Stopping Dinâmico:** Os autores originais forçaram um treino estático de 5 épocas, o que naturalmente causou sobreajuste (overfitting) nas épocas finais. Substituímos essa abordagem por um monitoramento contínuo da perda de validação (*Validation Loss*) com paciência de 2 épocas. Isso permitiu congelar e restaurar os pesos no "pico de inteligência" do modelo (Época 1 para o Twitter, Época 2 para o IMDb, e Época 3 para o Sentiment140), o que justificou a superação da *baseline* original em até 7,16%.

3. Distribuição e Volume de Dados Treinados




Figura 1: Distribuição do volume exato de instâncias presentes na fatia de 90% de treino processada pelo modelo.

Análise da Distribuição: A figura acima materializa a densidade estatística com a qual o modelo híbrido foi treinado, refletindo os valores exatos resultantes de um partilhamento matemático dinâmico ($seed=42$).

- **(a) Twitter US Airline:** Apresenta um forte desbalanceamento natural, focado prioritariamente em reclamações de consumidores. O modelo processou 8.222 instâncias negativas contra 2.803 neutras e 2.151 positivas. Foi justamente este baixo volume de dados aliado ao desbalanceamento que fez com que o nosso *Early Stopping* interrompesse o treino logo na Época 1, impedindo a rede de decorar o ruído.
- **(b) IMDb Review:** Ilustra uma base de dados altamente equilibrada. O modelo treinou com um volume substancial e quase perfeitamente simétrico de avaliações de filmes (22.525 negativas e 22.475 positivas), justificando a rápida convergência e a acurácia superior a 92% na época 2.
- **(c) Sentiment140:** Evidencia o verdadeiro poder de escala do pipeline otimizado com AMP. O modelo ajustou os seus pesos processando um volume colossal de dados balanceados: 719.729 tweets negativos e 720.271 positivos. Essa prova visual da quantidade massiva de conhecimento empírico injetada na rede é o que fundamenta matematicamente o salto brutal de performance obtido nesta replicação em relação aos resultados sub-amostrados do artigo original.

4. Resultados e Comparativo de Performance

Tabela 1: Resumo da Execução e Otimização

Parâmetros fixos: AMP Ativado, Batch Size = 16, Learning Rate = $1e-05$, Hidden Dim = 256.

Dataset	Tempo de Treino	Melhor Época (Paciência=2)	Otimização
Sentiment140	14h 11m 38s	3	AMP (16-bit)
IMDb	21m 07s	2	AMP (16-bit)
Twitter US Airline	04m 43s	1	AMP (16-bit)

Tabela 2: Comparativo de Performance (Nossa Replicação vs. Artigo Original)

As métricas lado a lado comprovam o ganho de generalização ao utilizar *Early Stopping* dinâmico e um split de treino otimizado.

Dataset	Acurácia (Obtida / Artigo)	Precisão (Obtida / Artigo)	Recall (Obtido / Artigo)	F1-Score (Obtido / Artigo)	Salto de Performance
Sentiment140	89.41% / 82.25%	89.42% / 82.25%	89.41% / 82.25%	89.41% / 82.25%	+ 7.16% 🚀
Twitter Airline	85.66% / 80.74%	86.73% / 80.94%	85.66% / 80.74%	86.03% / 80.73%	+ 4.92% 🚀
IMDb	92.32% / 92.36%	92.33% / 92.46%	92.32% / 92.36%	92.32% / 92.35%	- 0.04% 🎯